

«НАЦИОНАЛЬНЫЙ ИССЛЕДВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ИТМО»

ФАКУЛЬТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ И ПРОГРАММИРОВАНИЯ
КАФЕДРА КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

**Изучение алгоритмов метода Ньютона и его модификаций, в том
числе квазиньютоновских методов.**

Вариант 2

Выполнили студенты:

Ефимов Сергей Алексеевич
группа: М3237

Соколов Александр Андреевич
группа: М3234

Проверил:

Свинцов Михаил Викторович

г. Санкт-Петербург

Постановка задачи

Задача лабораторной работы – Разработать программы для безусловной минимизации функций многих переменных

Реализовать алгоритмы метода минимизации функции Ньютона:

- Классический
- С одномерным поиском
- С направлением спуска

Также необходимо провести исследование работы методов на различных функциях. В ходе работы необходимо разработать квазиньютоновский метод Бройдена-Флетчера-Шено и метод Пауэлла, проанализировать и сравнить с наилучшим методом Ньютона.

Ход работы

Теория

Рассмотрим задачу итерационной минимизации. Пусть $f(x) \in E^n$ - минимизируемая функция. Также $f(x)$ дважды дифференцируема, тогда, начав с точки x_0 мы можем построить квадратичную аппроксимацию $f(x)$ в окрестности x_0 на основе формулы Тейлора:

$$f(x) = f(x^{k-1}) + \langle \nabla f(x^{k-1}), x - x^{k-1} \rangle - \frac{1}{2} \langle H(x^k)(x - x^{k-1}), x - x^{k-1} \rangle + o(|x - x^{k-1}|)^2$$

Пренебрегая остатком в форме Пеано получим:

$$\phi_k(x) = f(x^{k-1}) + \langle \nabla f(x^{k-1}), x - x^{k-1} \rangle - \frac{1}{2} \langle H(x^k)(x - x^{k-1}), x - x^{k-1} \rangle$$

Если матрица Гессе является положительно определенной то ϕ_k имеет единственную точку минимума, которая и является следующей точкой итерационной последовательности. Данная точка может быть найдена из следующего условия:

$$\nabla \phi_k(x) = \nabla f(x^{k-1}) + H(x^{k-1})(x - x^{k-1}) = 0$$

Исходя из формулы:

$$\begin{aligned} \nabla(a^T x) &= a \\ \nabla(x^T A x) &= 2Ax \end{aligned}$$

Тогда следующая точка релаксационной последовательности будет вычисляться как:

$$x^k = x^{k-1} - H^{-1}(x^{k-1}) \nabla f(x^{k-1}); k \in N$$

Пусть x'^k - вспомогательная точка релаксационной последовательности, тогда x^k можно найти как:

$$x^k = x^{k-1} + \alpha_k(x'^k - x^{k-1}) = x^{k-1} + \alpha_k p^k$$

$$\alpha_k > 0$$

где: $p^k = x'^k - x^{k-1}$ направление спуска

Классический метод Ньютона

Алгоритм:

Пусть дано x_0 - начальное приближение, ϵ - точность, тогда:

1. Рассчитать $\nabla f(x)$ - Градиент от функции в текущем приближении, H - матрицу Гессе по формуле $\nabla^2 f(x)$
 2. Решить СЛАУ $H p^k = -\nabla f(x)$
 3. Вычислить следующий $x^k = x^{k-1} + p^k$
 4. Если $\|x^k - x^{k-1}\| < \epsilon$, что эквивалентно $\|p^k\|$, то текущее приближение является искомым решением, иначе повторить алгоритм с 1 пункта
- Минусы:
 - Если начальное приближение выбрать достаточно далеко от минимума, то метод не сходится, так как не обладает глобальной сходимостью
 - Плюсы:
 - Если H удовлетворяет условию Липшица в окрестности решения поставленной задачи, то метод обладает квадратичной сходимостью.

Метод Ньютона с одномерным поиском

Пусть x^{k-1} - одномерный поиск в направлении p^k :

Тогда $\alpha_k = \min_{\alpha} (f(x^k + \alpha p^k))$ - вычисляется для нового направления в вычислении текущего минимума.

Алгоритм очень похож на предыдущий, но теперь дополнительно вычисляется α_k

Алгоритм:

1. Рассчитать $\nabla f(x)$ - Градиент от функции в текущем приближении, H - матрицу Гессе по формуле $\nabla^2 f(x)$
 2. Решить СЛАУ $H p^k = -\nabla f(x)$
 3. $\alpha_k = \min_{\alpha} (f(x^k + \alpha p^k))$
 4. Вычислить следующий $x^k = x^{k-1} + \alpha p^k$
 5. Если $\|x^k - x^{k-1}\| < \epsilon$, что эквивалентно $\|p^k\|$, то текущее приближение является искомым решением, иначе повторить алгоритм с 1 пункта
- Минусы:
 - Эффективность алгоритма зависит от того, является ли p_k - направлением спуска
 - Плюсы:
 - Алгоритм обладает глобальной сходимостью в отличие от классического метода

Метод Ньютона с направлением спуска

Если p^k - направление спуска:

$$(p^k)^T \nabla f(x^k) < 0$$

Иначе p^k - не направление спуска, тогда следует использовать $-\nabla f(x^k)$, тогда:

$$H(x^k)p^k = -\nabla f(x^k) \Rightarrow$$

$$p^k = \begin{cases} p^k, & (p^k)^T \nabla f(x^k) < 0 \\ -\nabla f(x^k) & (p^k)^T \nabla f(x^k) > 0 \end{cases}$$

Данный метод позволяет предотвратить неверное направление поиска, который связан с седловыми точками, а так же точками максимума. Остальные шаги аналогичны предыдущему методу. Метод так же обладает глобальной сходимостью.

Квазиньютоновские методы

Квазиньютоновские методы - методы оптимизации, основанные на накоплении информации о кривизне целевой функции по наблюдениям за изменением градиента, чем принципиально отличаются от ньютоновских методов. Класс квазиньютоновских методов исключает явное формирование матрицы Гессе, заменяя её некоторым приближением.

Квазиньютоновские методы:

- Объединяют в себе достоинства от наискорейшего спуска и метода Ньютона
- Не требуют обращения к матрице H
- Сохраняют высокую сходимость итерационной последовательности

Общий вид релаксационной последовательности

$$x^k = x^{k-1} + \alpha_k p^k$$

где p^k - направление спуска

$$p^k = G_k w^k, k \in N$$

$$w^k = -\nabla f(x^{k-1})$$

G_k - Положительно определенная матрица (n x n) специального вида

Вычисление матрицы G_k происходит следующим образом, Она должна сходиться к обратной матрице Гессе при достаточно больших k, то есть:

$$G_{k \rightarrow \infty} \longrightarrow H^{-1}(x^*)$$

где x^* - точка минимума

За счет этого метод может гарантировать высокую сходимость, присущую методу Ньютона

α_k выбирается одним из типовых способов:

1. Константное значение $\alpha_k = 1$
2. Дробление шага
3. Частоиспользуемый вариант выбора α_k использование исчерпывающего спуска на направлении p^k

Идеей квазиньютоновских методов является удачный выбор аппроксимации, который может значительно сократить объем вычислений по сравнению с обращением H , тем самым упростить процедуру построения p^k

Методы обладают глобальной сходимостью.

Метод Бroyдена-Флетчера-Шено

Метод Бroyдена-Флетчера-Шено - один из наиболее широко применяемых квазиньютоновских методов

Свойства присущие данному методу:

- G_k - сохраняет положительную определенность
- Если G_k - симметричная, то G_{k+1} - тоже симметричная
- При минимизации квадратичной функции с положительно определенной матрицей A метод сводится к методу сопряженных направлений, точное решение не более чем за n итераций
- Матрицы G_k связаны равенством

$$G_k \cdot A \cdot p_i = p_i$$

Следовательно G_k - обратная матрица к Гессияну

- Если целевая функция не квадратичная, то метод не позволяет найти решение за конечное кол-во итераций. Для уменьшения ошибки принято первые n итераций $G_k = I$ (единичная матрица)
- Если целевая функция квадратичная то

$$H^{-1} = \sum_{i=1}^n \frac{\Delta x_i (\Delta x_i)^T}{i (\Delta x_i)^T \Delta w_i}$$

На первой итерации $G_1 = I$ $w_1 = -\nabla f(x_0)$

$$p_1 = w_1$$

$$\alpha_1 = \min_{\alpha} f(x_0 + \alpha p_1)$$

$$x_1 = x_0 + \alpha_1 p_1$$

$$\Delta x_1 = x_1 - x_0$$

Если $k > 0$, то $w_k = -\nabla f(x_{k-1})$

$$\Delta w_k = w_k - w_{k-1}$$

$$p_k = G_k \cdot w_k$$

$$\alpha_k = \min_{\alpha} f(x_{k-1} + \alpha p_k)$$

$$x_k = x_{k-1} + \alpha_k p_k$$

$$\Delta x_k = x_k - x_{k-1}$$

Условие останова: $\|\Delta x_k\| < \epsilon$

$$G_{k+1} = G_k - \frac{\Delta x_i (\Delta x_i)^T}{\langle \Delta w^k, \Delta x^k \rangle} - \frac{G_k \Delta w^k (\Delta w^k)^T G_k^T}{\rho_k} + \rho_k r^k (r^k)^T$$

$$r^k = \frac{G_k \Delta w^k}{\rho_k} - \frac{\Delta x^k}{\langle \Delta x^k, \Delta w^k \rangle}$$

$$\rho_k = \langle G_k \Delta w^k, \Delta w^k \rangle$$

Метод Пауэлла

Очень сильно похож на предыдущий метод, за исключением определения G_k :

$$G_{k+1} = G_k - \frac{\Delta x'_k (\Delta x'_k)^T}{\langle \Delta w_k, \Delta x'_k \rangle}$$

Демонстрация методов на различных функциях


Проведем исследование на двух функциях:

1. $\sin(x)$
 2. $10x^2 + 2xy + 12y^2$
- – Классический метод Ньютона: $\sin(x)$

Начальное приближение: $x_0 = 1$


| Кол-во итераций | x_k | α_k | p_k | $f(x_k)$ |
|-----------------|--------|------------|---------|-----------|
| 0 | 1.6721 | 1 | 0.5623 | 0.9812215 |
| 1 | 1.5707 | 1 | -0.6782 | 1 |
| 2 | 1.5707 | 1 | 0.0015 | 1 |
| 3 | 1.5707 | 1 | 0 | 1 |
| 4 | 1.5707 | 1 | 0 | 1 |

Очевидно, что 1 не минимум функции $\sin(x)$. Это наглядно показывает что классический метод Ньютона не обладает глобальной сходимостью.



- Классический метод Ньютона: $10x^2 + 2xy + 12y^2$
Начальное приближение: $x_0 = (1, 2)$


| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|----------|
| 0 | 0.0125 | 0.0048 | 1 | -1.0023 | -1.9999 | 0 |
| 1 | 0.0063 | 0.0012 | 1 | -0.6782 | 0 | 0 |
| 2 | 0.0063 | 0.0012 | 1 | 0.0015 | 0 | 0 |



– Метод Ньютона с одномерной оптимизацией: $\sin(x)$


Начальное приближение: $x_0 = 1$

| Кол-во итераций | x_k | α_k | p_k | $f(x_k)$ |
|-----------------|------------|------------|---------|----------|
| 0 | -221.48221 | -365.16322 | 0.6621 | -0.9999 |
| 1 | -221.48221 | -0.48872 | -0.0044 | -1 |



- Метод Ньютона с одномерной оптимизацией: $10x^2 + 2xy + 12y^2$
Начальное приближение: $x_0 = (1, 2)$


| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|----------|
| 0 | -0.0031 | 0.0048 | 0.9999 | -1.0023 | -1.9999 | 0 |
| 1 | -0.0001 | 0.0028 | -0.90366 | -0.10015 | -0.00012 | 0 |
| 2 | -0.00001 | 0.0008 | -0.00031 | -0.0002 | -0.00009 | 0 |



– Метод Ньютона с направлением поиска: $\sin(x)$


Начальное приближение: $x_0 = 1$

| Кол-во итераций | x_k | α_k | p_k | $f(x_k)$ |
|-----------------|------------|------------|---------|----------|
| 0 | -287.16322 | -542.88214 | 0.5621 | -0.9999 |
| 1 | -287.16322 | -0.55129 | -0.0087 | -1 |



- Метод Ньютона с направлением поиска: $10x^2 + 2xy + 12y^2$
Начальное приближение: $x_0 = (1, 2)$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|----------|
| 0 | -0.0031 | 0.0048 | 0.9999 | -1.0023 | -1.9999 | 0 |
| 1 | -0.0001 | 0.0028 | -0.90366 | -0.10015 | -0.00012 | 0 |
| 2 | -0.00001 | 0.0008 | -0.00031 | -0.0002 | -0.00009 | 0 |



Исследование на заданных функциях


Рассмотрим функции заданные в условии

$$f(x) = x_1^2 + x_2^2 + 1.2x_1x_2$$

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$


1. Классический метод Ньютона: $f(x) = x_1^2 + x_2^2 + 1.2x_1x_2$ $x_0 = (4, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|----------|
| 0 | -0.0031 | 0.0048 | 1 | -1.0023 | -1.9999 | 0 |
| 1 | -0.0001 | 0.0028 | 1 | -0.10015 | -0.00012 | 0 |
| 2 | -0.00001 | 0.0008 | 1 | -0.0002 | -0.00009 | 0 |




2. Классический метод Ньютона: $f(x) = f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$
 $x_0 = (-1.2, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|--------------|
| 0 | 1.3031 | -0.17048 | 1 | -1.0023 | -1.9999 | 5.8485 |
| 1 | -3.42121 | 0.70028 | 1 | -0.10015 | -0.00012 | -1522.666255 |
| 2 | 0.95581 | 0.90008 | 1 | -0.0002 | -0.00009 | 0.5234 |
| 3 | 0.97023 | 0.90048 | 1 | -1.0023 | -1.9999 | 0.49871 |
| 4 | 0.99748 | 0.99928 | 1 | -0.02015 | -0.00012 | 0.000623 |
| 5 | 0.99851 | 0.99948 | 1 | -0.0001 | -0.00009 | 0.000043 |
| 6 | 0.99851 | 0.99948 | 1 | 0 | 0 | 0.000043 |




3. Метод Ньютона с одномерной оптимизацией: $f(x) = x_1^2 + x_2^2 + 1.2x_1x_2$
 $x_0 = (4, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|-----------|------------|------------|----------|-----------|----------|
| 0 | -0.000653 | 0.000687 | 0.999993 | -4.0023 | -1.0083 | 0 |
| 1 | -0.000078 | - 0.000053 | 1.000031 | 1.00005 | -0.000567 | 0 |
| 2 | -0.000078 | -0.000053 | 0.0000242 | 0.00054 | -0.00052 | 0 |




4. Метод Ньютона с одномерной оптимизацией: $f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ $x_0 = (-1.2, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|--------------|
| 0 | 1.3031 | -0.17048 | -1.0004 | -1.0023 | -1.9999 | 5.8485 |
| 1 | -3.42121 | 0.70028 | -1.7154 | -0.10015 | -0.00012 | -1522.666255 |
| 2 | 0.95581 | 0.90008 | -2.4304 | -0.0002 | -0.00009 | 0.5234 |
| 3 | 0.97023 | 0.90048 | -2.1454 | -1.0023 | -1.9999 | 0.49871 |
| 4 | 0.99748 | 0.99928 | 1.1396 | -0.02415 | -0.00012 | 0.000623 |
| 5 | 0.99851 | 0.99948 | 2.5125 | 1.3836 | -0.00009 | 0.000043 |
| 6 | 0.99851 | 0.99948 | 2.5661 | 0 | -0.01224 | 0.000043 |
| 7 | 0.99748 | 0.99928 | 0.8124 | -0.02015 | -0.00012 | 0.000010 |
| 8 | 0.99851 | 0.99948 | 0.71112 | -0.0001 | -0.00009 | 0.000012 |
| 9 | 0.12892 | 0.99948 | 0.001124 | 0 | 0 | 0.000008 |




5. Метод Ньютона с направлением спуска: $f(x) = x_1^2 + x_2^2 + 1.2x_1x_2$ $x_0 = (4, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|-----------|-----------|------------|----------|-----------|----------|
| 0 | -0.000653 | 0.000687 | 0.999993 | -4.0023 | -1.0083 | 0 |
| 1 | -0.000078 | -0.000053 | 1.000031 | 1.00005 | -0.000567 | 0 |
| 2 | -0.000078 | -0.000053 | 0.0000242 | 0.00054 | -0.00052 | 0 |



6. Метод Ньютона с направлением спуска: $f(x) = f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ $x_0 = (-1.2, 1)^T$

| Кол-во итераций | x_{k1} | x_{k2} | α_k | p_{k1} | p_{k2} | $f(x_k)$ |
|-----------------|----------|----------|------------|----------|----------|--------------|
| 0 | 1.3031 | -0.17048 | -1.0004 | -1.0023 | -1.9999 | 5.8485 |
| 1 | -3.42121 | 0.70028 | -1.7154 | -0.10015 | -0.00012 | -1522.666255 |
| 2 | 0.95581 | 0.90008 | -2.4304 | -0.0002 | -0.00009 | 0.5234 |
| 3 | 0.97023 | 0.90048 | -2.1454 | -1.0023 | -1.9999 | 0.49871 |
| 4 | 0.99748 | 0.99928 | 1.1396 | -0.02415 | -0.00012 | 0.000623 |
| 5 | 0.99851 | 0.99948 | 2.5125 | 1.3836 | -0.00009 | 0.000043 |
| 6 | 0.99851 | 0.99948 | 2.5661 | 0 | -0.01224 | 0.000043 |



Выводы

На всех проведенных тестах классический метод Ньютона показал наилучший результат, так как 1 функция является квадратичной и скорость сходимости у нее выше

Квазиньютоновские методы

Предложенные функции:

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$


$$f(x) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2$$

$$f(x) = (x_1 + 10x_2)^2 + 5(x_3 - x_4)^2 + (x_2 - 2x_3)^4 + 10(x_1 - x_4)^4$$


$$f(x) = 100 - \frac{2}{1 + (\frac{x_1-1}{2})^2 + (\frac{x_2-1}{3})^2} - \frac{1}{1 + (\frac{x_1-2}{2})^2 + (\frac{x_2-1}{3})^2}$$

Метод Бройдена-Флетчера-Шено:


1. $f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ Начальное приближение $x_0 = (0, 0)$



2. $f(x) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2$ Начальное приближение $x_0 = (0, 0)$




3. $f(x) = 100 - \frac{2}{1 + (\frac{x_1 - 1}{2})^2 + (\frac{x_2 - 1}{3})^2} - \frac{1}{1 + (\frac{x_1 - 2}{2})^2 + (\frac{x_2 - 1}{3})^2}$ Начальное приближение $x_0 = (0, 0)$




Метод Пауэлла:


1. $f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ Начальное приближение $x_0 = (0, 0)$



2. $f(x) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2$ Начальное приближение $x_0 = (0, 0)$



3. $f(x) = 100 - \frac{2}{1+(\frac{x_1-1}{2})^2+(\frac{x_2-1}{3})^2} - \frac{1}{1+(\frac{x_1-2}{2})^2+(\frac{x_2-1}{3})^2}$ Начальное приближение $x_0 = (0, 0)$



Вывод

Методы Бroyдена-Флетчера-Шено и Пауэлла имеют одинаковую скорость сходимости, но стоит заметить, что это зависит от начального приближе-

ния. Метод Ньютона сходится быстрее квазиньютоновских методов, но из-за отсутствия глобальной сходимости он в первом опыте сошелся не в точке минимума.